

5G & YAPAY ZEKA İLE AKILLI YOL GÜVENLİĞİ YARIŞMASI ÖN TASARIM RAPORU ŞABLONU

Takım Adı: anomali

Takım ID: 910433

Başvuru ID: 4905867



İÇİNDEKİLER

1. PROJE ÖZETİ (5 PUAN)	3
2. TAKIM ŞEMASI.....	3
3. SİSTEM ÖN TASARIMI (55 PUAN)	4
3.1. Genel Sistem Mimarisi ve Veri Akış Şeması (15 Puan)	4
3.2. Yapay Zeka Modeli ve Çıkarım Tasarımı (20 Puan)	5
3.3. Yazılım Mimari Tasarımı (20 Puan).....	6
4. YÖNTEM (20 PUAN).....	7
1. Yöntem	7
5. ÖZGÜNLÜK (10 PUAN).....	9
6. ZAMAN PLANLAMASI (5 PUAN).....	9
7. PROJE RAPOR DÜZENİ VE KAYNAKÇA (5 PUAN).....	10

1. PROJE ÖZETİ (5 PUAN)

Bu proje, 5G'nin programlanabilir ağ yetenekleri ile yapay zekâ tabanlı canlı video analizini tek bir karar hattında birleştirerek yol güvenliği açısından kritik durumları tespit etmeyi ve her tespiti denetlenebilir bir kanıt paketiyle belgelemeyi amaçlamaktadır. Mobil uygulama kamera görüntüsünü alır, kullanıcı/cihaz oturumunu Number Verification ile doğrular ve video akışını edge/arka uçtaki yapay zekâ çıkarım hattına iletir. Araç tespiti, sahne/koşul analizi, takip tabanlı risk değerlendirmesi, plaka okuma, hız kestirimi ve araç içi risk görevleri tek bir büyük model yerine seçici çalışan alt bileşenler olarak tasarlanmıştır. [1]

Tasarımın temel yaklaşımı, ağ ve hesaplama kaynaklarını sürekli yüksek maliyetli modda kullanmak yerine olay ihtiyacına göre yönetmektir. Normal izleme modunda hafif analiz hattı çalışır; hedef araç yaklaşımı, plaka okuma ihtiyacı, görüş kalitesi düşüşü, takip tabanlı risk sinyali veya araç içi risk şüphesi belirginleştğinde sistem kritik moda geçer. Bu pencerede Quality on Demand (QoD), yalnızca karar güveni veya kanıt kalitesine katkı sağlayacağı durumlarda geçici ağ yükseltme mekanizması olarak değerlendirilir ve yalnız ilgili uzman modeller çağrılır. [3][4]

Ön tasarım aşamasındaki çalışmalar, bitmiş saha performansı iddiası yerine uygulanabilir mimari ve doğrulanabilir karar zinciri kurmaya odaklanmıştır. Sahne/koşul analizi için ResNet18 tabanlı baseline iskeleti hazırlanmış; “video → kare → ön işleme → tensör → çıkarım → softmax → JSON raporlama” zinciri üç resmî test videosunda çalışır durumda doğrulanmıştır. Bu çıktı performans kanıtı değil, uçtan uca çıkarım hattının çalışırılık kanıtıdır. Mobil tarafta Kotlin, Jetpack Compose ve CameraX tabanlı uygulama iskeleti ile Number Verification, QoD ve edge streaming adapter arayüzleri hazır durumdadır. [5][6]


2. TAKIM ŞEMASI

Sıra	Takımdaki Görevi	Eğitim Seviyesi	Sınıf	Üye Rolü
1	İş planı, sprint takibi, entegrasyon koordinasyonu, rapor bütünlüğü, demo akışı	Lisans	3	Kaptan
2	Mobil uygulama (Kotlin, Compose, CameraX), Number Verification adapter, arayüz	Lisans	3	Üye
3	Veri envanteri, araç tespiti/takibi, sahne/koşul analizi, risk kararı, metrik	Lisans	3	Üye
4	Plaka/OCR, hız, araç içi risk, edge servisleri, QoD orkestrasyonu, log/kanıt	Lisans	3	Üye

3. SİSTEM ÖN TASARIMI (55 PUAN)

3.1. Genel Sistem Mimarisi ve Veri Akış Şeması (15 Puan)

Önerilen sistem mimarisi; mobil istemci, video akış katmanı, edge/arka uç yapay zekâ çıkarım hattı, karar/QoD orkestrasyon katmanı, uzman analiz bileşenleri ve olay/kanıt katmanından oluşan modüler bir yapıdır. Mobil uygulama kamera görüntüsünü alır, kullanıcı/cihaz oturumunu Number Verification mantığıyla doğrular ve canlı video akışını düşük gecikmeli iletişim adapteri üzerinden edge tarafına iletir. WebSocket ve WebRTC/WHIP protokolleri değerlendirme altındadır; bu aşamada uygulama ve edge bağlantısı adapter arayüzü arkasında soyutlanacaktır. [3][4][5]




Şekil-1: Genel Sistem Mimarisi ve Veri Akış Şeması

Şekil 1’de gösterildiği gibi edge tarafında video akışı alım ve ön işleme katmanından geçtikten sonra hafif analiz hattı araç tespiti, araç takibi ve sahne/koşul sinyallerini üretir. Kritik pencere oluştuğunda mod/model yönlendirme katmanı devreye girerek çağrılacak uzman modelleri ve QoD adaylığını politika kurallarına göre belirler. Karar sonuçları; olay kartı, risk/güven skoru, QoD durumu ve karar gerekçeleriyle birlikte mobil arayüze döner.

Her kritik olay için olay kimliği, UTC zaman damgası, kaynak kare/kesit, kutu koordinatları, iz kimliği, güven skoru, risk seviyesi, seçilen mod, çağrılan uzmanlar, QoD durumu, karar gerekçesi ve model sürümü alanlarını içeren bir kanıt paketi oluşturulur. Bu paket yalnızca gösterim çıktısı değil; otomatik analiz sonucunun sonradan denetlenebilir olmasını sağlayan kayıt yapısıdır. [1][2]

3.2. Yapay Zeka Modeli ve Çıkarım Tasarımı (20 Puan)

Yapay zekâ hattı, tek büyük modelin tüm problemleri çözmesine dayanmayan; sahne/koşul analizi, araç tespiti-takibi, riskli araç ön değerlendirmesi, mod yönlendirmesi ve gerektiğinde çağrılan uzman modellerden oluşan çok aşamalı bir mimari olarak tasarlanmıştır. Bu tercih, araç tespiti, plaka okuma, hız kestirimi, sahne koşulu ve araç içi risk görevlerinin aynı çözünürlük, aynı ROI ve aynı zaman penceresi beklentisini paylaşmamasından kaynaklanır. Normal modda hafif ve sürekli çalışan analiz hattı, kritik modda ise seçici uzman çağrısı çalışır; mod geçişinin tetik koşulları ve karar adımları Şekil 2'de özetlenmiştir. [1]



Şekil-2: Olay Temelli Karar Akışı

Normal modda araç tespiti için hafif YOLO ailesi, iz sürekliliği için ByteTrack benzeri tracker ve sahne/koşul analizi için ResNet18 tabanlı yardımcı sınıflandırıcı öngörülmektedir. ResNet18 nihai model değil, literatürle savunulabilir akademik bir baseline olarak konumlandırılmıştır. Sahne/koşul etiket uzayı beş sınıfa ayrılmıştır: açık gündüz, açık düşük ışık, yağışlı hava, sis/pus ve çok düşük görüş. Bu sınıflandırma, uzman model yönlendirme ve QoD kararına bağlamsal sinyal sağlamak amacıyla tasarlanmıştır. [6][7][8]

Kritik modda uzman çağrı politikası koşul ve görev farkındalığıyla çalışır. Koşul uzmanları sahne/koşul çıktısı ve belirsizliğe göre; görev uzmanları ise risk sinyali, iz kararlılığı, ROI yeterliliği, kanıt değeri ve QoD fayda skoruna göre seçilir. Tüm uzmanlar aynı anda çalıştırılmaz; normal modda en fazla iki, kritik modda en fazla üç görev uzmanı çalışacak şekilde seyrek uzman seçimi uygulanır. Sahne sınıfı ile görev uzmanı arasındaki eşleşme ve QoD-fayda dağılımı Şekil 3'te verilmiştir. [3][4]

 Sahne Sınıfı	 Araç Tipi	 Şerit İhlali	 Hız Kestirimi	 Araç İçi Risk	 Plaka OCR	 Koşul Uzmanı
 Açık Gündüz	Orta	Yüksek	Yüksek	Orta	Orta	 Normal Gündüz
 Açık Düşük Işık	Orta	Orta	Orta	Yüksek / QoD	Yüksek / QoD	 Gece / Düşük Işık
 Yağışlı Hava	Düşük	Orta	Orta	Orta	Yüksek / QoD	 Kötü Görüş / Hava Koşulu
 Sis / Pus	Düşük	Düşük	Orta / QoD	Orta	Yüksek / QoD	 Kötü Görüş / Hava Koşulu
 Çok Düşük Görüş	Düşük	Düşük	Düşük	Orta / QoD	Orta / QoD	 Kötü Görüş / Hava Koşulu

Şekil-3: Uzman Seçim Matrisi

Plaka/OCR hattı; araç ROI, plaka bölgesi, OCR, zamansal oy birliği ve format kontrolü adımlarından oluşur. Hız kestiriminde homografi destekli iz tabanlı tahmin, kalibrasyon yetersizse görelî hız ve hareket aykırılığı yaklaşımı kullanılacaktır. Araç içi risk analizinde telefon, sigara, emniyet kemeri ve yüz/baş/el konumu gibi ipuçları kısa zaman pencerelerinde değerlendirilir. Tüm çıktılar iz kimliği, zaman penceresi, güven skoru ve karar gerekçesiyle birlikte standart olay şemasına dönüştürülür. [8][9]


QoD her kritik durumda otomatik açılmaz; mod, uzmanların QoD-fayda sınıfı ve mevcut ağ kalitesi birlikte değerlendirilir. En yüksek QoD faydası plaka OCR, araç içi risk ve hız kestirimi görevlerinde beklenmektedir; düşük faydalı uzmanlarda veya ağ kalitesi yeterliyse QoD talebi üretilmez. [3][4]

Ön tasarımda ResNet18 tabanlı sahne/koşul modülünün çalışırllığı RGB ve gri seviye giriş hatlarıyla doğrulanmış; “video → forward → JSON” zinciri üç resmî test videosunda çalıştırılarak artefakt üretilmiştir. Bu çıktılar benchmark değil, uçtan uca hattın çalışırllık doğrulamasıdır. Dağıtımda PyTorch geliştirme ortamı, ONNX Runtime hedef çalışma zamanı; TensorRT/OpenVINO, FP16/INT8 quantization, çözünürlük kontrolü ve batch/async çıkarım ise optimizasyon seçenekleri olarak planlanmaktadır. [

3.3. Yazılım Mimari Tasarımı (20 Puan)

Önerilen yazılım mimarisi, mobil istemci ile edge/arka uçtaki yapay zekâ ve karar bileşenlerini net adapter sınırlarıyla ayıran modüler bir yapıdır. Mobil tarafta Android tabanlı istemci Kotlin, Jetpack Compose, Material 3 ve CameraX üzerine kurulmuştur. Bu aşamada uygulama iskeleti çalışır durumdadır: CameraX Preview + ImageAnalysis, runtime kamera izni, canlı önizleme ve durum göstergeleri hazır; LoginScreen, LiveScreen ve EventsScreen için navigasyon iskeleti yerleştirilmiştir. Number Verification ve Quality on Demand istemcileri mock implementasyonlar

arkasında, edge akış taşıyıcı ise stub arkasında tutulmaktadır. Operatör SDK'ları ve edge uç noktaları netleştğinde aynı arayüz sözleşmesi korunarak taşıyıcı katman



değiştirilecek, uygulama kodu etkilenmeyecektir. Katmanların mobil–edge bölüşümü ve adapter sınırları Şekil 4'te verilmiştir. [5]


Şekil-4: A-E Katmanlı Yazılım Mimarisi

Edge/arka uç tarafı video alımı, ön işleme, model çıkarımı, karar üretimi, uzman çağrıları, olay kaydı ve sonuç iletiminden sorumludur. Bu katman Python tabanlıdır. A katmanı mobil bağlantı ve video alımını; B katmanı sahne/koşul sinyalini; C katmanı takip tabanlı riskli araç olaylarını; D katmanı normal/kritik mod, QoD aksiyonu ve uzman seçimini; E katmanı ise plaka/OCR, hız, şerit/takip, araç tipi ve araç içi risk analizlerini yürütür. Uzman seçim politikası bir JSON konfigürasyonunda tutulur; koşul kuralları, aktivasyon eşikleri, QoD öncelik eşlemesi ve fallback kuralları kod dışında kalarak test edilebilir ve güncellenebilir olur. [1][2]

Eşzamanlılık ve kaynak yönetiminde ilke seçici aktivasyondur: ağır uzmanlar her karede çalıştırılmaz, yalnız kritik pencere oluştuğunda ilgili alt küme çağrılır. Sonuçlar hafif bir iletişim kanalı (REST ve/veya WebSocket tabanlı olay bildirimi) üzerinden mobil arayüze olay kartı, risk/güven skoru, QoD durumu ve kanıt referansları olarak döner. Gözlemlenebilirlik için yapısal loglama, olay kimliği tabanlı izleme ve model sürüm etiketleme mimariye baştan dahil edilmiştir. [1][2]

4. YÖNTEM (20 PUAN)

1.Yöntem



Çalışma yöntemi, yarışmanın aşamalarına uygun olarak kademeli geliştirme yaklaşımıyla planlanmıştır. İlk aşamada hedef, nihai saha performansı iddiası üretmek değil; çevrimdışı video/veri üzerinde çalışabilecek savunulabilir bir yapay zekâ çekirdeği, sistem mimarisi, karar mantığı ve kanıt üretim yapısı oluşturmaktır. Bu nedenle sistem; sahne/koşul analizi, araç tespiti ve takibi, riskli araç ön değerlendirme, mod/QoD yönlendirme, uzman model seçimi ve kanıt üretimi olmak üzere ayrı fakat birlikte çalışan modüller halinde ele alınacaktır. [1][2]

1.Aşama – Ön tasarım ve çevrimdışı doğrulama:

Bu aşamada veri envanteri çıkarılacak, kullanılacak model aileleri belirlenecek ve çevrimdışı video/kare akışı üzerinde temel çıkarım hattı kurulacaktır. Sahne/koşul analizi ile görüntü bağlamı üretilecek; araç tespiti ve takip çıktıları üzerinden ani yanal manevra, göreceli hız aykırılığı ve takip sürekliliği gibi risk sinyalleri değerlendirilecektir. Çıktılar yalnız sınıf etiketi olarak değil; zaman bilgisi, araç izi, kutu koordinatı, karar seviyesi, güven skoru ve karar gerekçesiyle birlikte kaydedilecektir. [1][2]

2. Aşama – Mobil uygulama ve 5G servis entegrasyonu:

Bu aşamada çevrimdışı yapay zekâ çekirdeği mobil istemci ve edge/sunucu servisleriyle bütünleştirilecektir. Mobil uygulama canlı görüntüyü alacak, kullanıcı/ cihaz doğrulama sürecini Number Verification mantığıyla yönetecek ve görüntü akışını edge/backend tarafına iletecektir. Sunucu tarafında hafif analiz hattı sürekli çalışacak; kritik pencere oluştuğunda mod yönlendirme katmanı ilgili uzman modelleri seçici biçimde çağıracaktır. Quality on Demand (QoD), her riskte otomatik açılan bir mekanizma değil; yalnız ağ kalitesi artışının karar güvenini veya kanıt değerini yükselteceği durumlarda aday olarak değerlendirilecektir. [3][4][5]



3. Aşama – Canlı sistem ve demo hazırlığı:

Final aşamada sistem uçtan uca senaryolar üzerinde test edilecektir. Mobil uygulamadan alınan görüntünün edge tarafına iletilmesi, sahne ve risk analizinden geçirilmesi, kritik mod kararının verilmesi, gerekiyorsa uzman modellerin çağırılması ve sonucun kullanıcı arayüzüne olay kartı olarak dönmesi doğrulanacaktır. Demo öncesinde normal mod, kritik mod, QoD adaylığı, uzman model çağırısı ve kanıt/log üretimi ayrı senaryolarla kontrol edilecektir. [1][2]



Geliştirme sürecinde testler dört düzeyde yürütülecektir: modül testleri, çevrimdışı video akışı testleri, QoD açık/kapalı A/B senaryo testleri ve canlı telefon-edge demo testleri. Değerlendirme metrikleri görev bazlı seçilecektir: araç tespiti için precision/recall, plaka okuma için plaka ve karakter düzeyi doğruluk, hız kestirimi için ortalama hata, araç içi risk analizi için F1 skoru; sistem düzeyinde ise uçtan uca gecikme, FPS, QoD oturum süresi ve olay kanıt bütünlüğü izlenecektir. Ön tasarım aşamasında bu metrikler henüz ölçülmemiştir; deney çıktıları elde edildikçe metrik tablosu güncellenecek ve ölçülmemiş değerler kesin başarı sonucu gibi sunulmayacaktır. [1][2]

5. ÖZGÜNLÜK (10 PUAN)

Önerilen sistemin özgünlüğü belirli bir model ailesi kullanmasında değil; yol güvenliği problemini 5G ağ yetenekleri, olay-temelli yapay zekâ, seçici uzman çağrısı ve kanıt üretimini tek karar zincirinde birleştiren mimari yaklaşımında ortaya çıkmaktadır. Quality on Demand (QoD), sürekli açık bir bağlantı özelliği olarak değil; sahne koşulu, risk seviyesi, model belirsizliği, uzmanların QoD-fayda sınıfı ve mevcut ağ kalitesi birlikte değerlendirilerek yalnız kısa ve anlamlı kritik pencerelerde aday olan bir mekanizma olarak tasarlanmıştır. Bu yaklaşım, 5G kaynağını sürekli premium bağlantı yerine kanıt değeri yüksek olaylar için seçici yükseltme olarak kullanır. [3][4]

İkinci özgün yön, uzman orkestrasyonunun koşul ve görev farkındalığıyla seyrek biçimde yapılmasıdır. Sistem; sahne/koşul çıktısını yalnız etiket olarak değil, uzman seçimi ve QoD kararını etkileyen bir yönlendirme sinyali olarak kullanır. Normal modda en fazla iki, kritik modda en fazla üç görev uzmanının çalıştırılması edge hesaplama bütçesini kritik olaylara yoğunlaştırır ve yalın bir YOLO+OCR zincirine göre daha kontrollü kaynak yönetimi sağlar. [7][8][9]

Üçüncü özgün yön, her kritik olayın denetlenebilir bir kanıt paketine dönüştürülmesidir. Zaman damgası, görüntü kesiti, kutu koordinatı, iz kimliği, güven skoru, seçilen mod, çağrılan uzmanlar, QoD durumu, karar gerekçesi ve model sürümü tek pakette saklanır. Böylece otomatik analiz sonucunun kanıtlanabilir olması sistemin sonradan eklenen değil, doğal bir parçası haline gelir. Aynı mimari; yol kenarı edge güvenlik kutusu, akıllı şehir video analitiği, filo güvenliği, mobil olay doğrulama ve trafik denetim desteği gibi uygulamalara da genişletilebilir. [1][3]

6. ZAMAN PLANLAMASI (5 PUAN)

Zaman planlaması yarışmanın aşamalı yapısıyla hizalı beş sprint üzerinden kurgulanmıştır. Proje takibi GitHub Projects üzerinden yapılacak; görevler yapay zekâ, mobil, edge/backend, 5G API entegrasyonu, test ve rapor/dokümantasyon başlıkları altında izlenecektir. Her sprint sonunda teknik çıktı, entegrasyon durumu ve rapora taşınabilecek kanıtlar birlikte değerlendirilir. [2]

7. PROJE RAPOR DÜZENİ VE KAYNAKÇA (5 PUAN)

Rapor, şablonda belirtilen biçim kurallarına (Arial 12 pt gövde, Arial Black 14 pt başlık, 1.15 satır aralığı, iki tarafa yaslı hizalama, üst 2.8 cm ve alt/sağ/sol 2.5 cm kenar boşluğu) uygun olarak hazırlanmıştır. Kapak ve İçindekiler sayfaları ayrı tutulmuş; kaynakça sonda verilmiştir. Rapor dili akademik, öz ve tekrardan kaçınan bir yapıdadır; ölçülmemiş çıktılar kesin başarı değeri olarak değil, plan ve doğrulama niteliğinde sunulmuştur. [2]

KAYNAKÇA

1. Türkiye Teknoloji Takımı Vakfı. (2026). 2026 5G ve Yapay Zekâ ile Akıllı Yol Güvenliği Yarışması Teknik Şartnamesi. TEKNOFEST.
2. Türkiye Teknoloji Takımı Vakfı. (2026). 2026 5G ve Yapay Zekâ ile Akıllı Yol Güvenliği Ön Tasarım Raporu Şablonu. TEKNOFEST.
3. GSMA. (2026). Open Gateway: Universal Network APIs. <https://www.gsma.com/solutions-and-impact/gsma-open-gateway/>
4. CAMARA Project. (2026). Quality on Demand API Documentation. Linux Foundation. <https://github.com/camaraproject/QualityOnDemand>
5. CAMARA Project. (2026). Number Verification API Documentation. Linux Foundation. <https://github.com/camaraproject/NumberVerification>
6. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. CVPR, 770–778.
7. Wang, A., Chen, H., Liu, L., et al. (2024). YOLOv10: Real-Time End-to-End Object Detection. arXiv:2405.14458.
8. Zhang, Y., Sun, P., Jiang, Y., et al. (2022). ByteTrack: Multi-Object Tracking by Associating Every Detection Box. ECCV, 1–21.
9. Du, Y., Li, C., Guo, R., et al. (2020). PP-OCR: A Practical Ultra Lightweight OCR System. arXiv:2009.09941.
10. Yu, F., Chen, H., Wang, X., et al. (2020). BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning. CVPR, 2636–2645.
11. Sakaridis, C., Dai, D., & Van Gool, L. (2021). ACDC: The Adverse Conditions Dataset with Correspondences for Semantic Driving Scene Understanding. ICCV, 10765–10775.